

Univerzitet u Beogradu  
Matematički fakultet

# **Primena genetskog algoritma na sistem za preporuku filmova**

## **Mentori**

prof. dr Vladimir Filipović  
asistent dr Stefan Kapunac

## **Autori**

Teodora Ivanović 90/2021  
Tijana Tošković 102/2021

Mart, 2026.

# SADRŽAJ

|                       |   |
|-----------------------|---|
| 1. Rezime             | 3 |
| 2. Priprema podataka  | 3 |
| 3. Genetski algoritam | 4 |
| 4. Autoenkoderi       | 5 |
| 5. Literatura         | 6 |

## 1. Rezime

Ovaj dokument predstavlja dokumentaciju za projekat razvijan u okviru kursa Računarska inteligencija na Matematičkom fakultetu Univerziteta u Beogradu.

U sklopu projekta je implementiran sistem za preporuku filmova. Umesto ručnog dizajniranja arhitekture neuronske mreže, projekat koristi genetski algoritam koji automatski pronalazi optimalnu strukturu autoenkodera za kreiranje embedinga za filmove. Takođe, projekat kombinuje nekoliko metoda za preporuku sadržaja:

- **filtriranje zasnovano na sadržaju** (engl. *content-based filtering*), koje se fokusira na karakteristike filmova kao što su žanr, godina objavljivanja, prosečna ocena;
- **kolaborativno filtriranje** (engl. *collaborative filtering*), koje analizira obrasce ponašanja korisnika kroz tzv. **faktorizaciju pomoću singularnih vrednosti** (engl. *SVD, Singular Value Decomposition*).

Genetski algoritam je pronašao jednostavnu, ali efikasnu arhitekturu (1 skriveni sloj, 32-dimenzionalni embedding) i srednja kvadratna greška rekonstrukcije iznosi  $\sim 0.0075$ . Sistem daje intuitivne i visoko kvalitetne preporuke, pronalazeći filmove i sa više od 95% sličnosti.

Za trening je korišćena poznata *MovieLens*<sup>1</sup> baza filmova, to jest, jedan njen podskup. Obrađeno je više od 9.000 filmova, odnosno više od 600 korisnika i više od 100.000 njihovih ocena filmova.

Od tehnologija, korišćeni su primarno programski jezik Python, a od biblioteka TensorFlow/Keras, NumPy, Pandas i scikit-learn. Od alata je korišćen sistem za verzionisanje Git.

## 2. Priprema podataka

Kompletna priprema podataka se nalazi u svesci [01 data preparation.ipynb](#). Dve glavne datoteke koje su korišćene su *movies.csv*, koja sadrži informacije o 9.742 filma i *ratings.csv*, koja sadrži 100.836 ocena korisnika. Za detaljniji uvid, konsultovati gorenavedenu svesku.

---

<sup>1</sup> <https://grouplens.org/datasets/movielens/>

### 3. Genetski algoritam

Umesto ručnog dizajniranja arhitekture neuronske mreže, projekat koristi NEAT-inspirisan (*NeuroEvolution of Augmenting Topologies*) genetski algoritam koji automatski pronalazi optimalnu strukturu autoenkodera. Kompletna implementacija algoritma se nalazi u svesci [02\\_genetic\\_algorithm.ipynb](#).

Ključna prednost leži u tome što algoritam započinje svoj rad sa minimalnom mrežom i evolucijom uvodi kompleksnost u mrežu samo onda kada je to zaista potrebno, time nas oslobađajući prekomerne potrebe za podešavanjem hiperparametara.

Svaka jedinka u populaciji predstavlja jednu arhitekturu autoenkodera. Cilj je da mreža nauči da komprimuje 57-dimenzionalne vektore filmova u manje vektore (tzv. latentni prostor, engl. *latent space*), a zatim ih rekonstruiše. Latentni prostor primorava mrežu da nauči najvažnije obrasce.

Funkcija prilagođenosti (engl. *fitness*) objedinjuje grešku rekonstrukcije na validacionom skupu podataka sa merom kompleksnosti mreže. Težimo da obe budu što manje, pa nam negativan predznak omogućava da vršimo minimizaciju funkcije prilagođenosti. Zapravo, ova formula implementira princip Okamove oštrice (engl. *Occam's razor*), koji favorizuje jednostavnije mreže kada su performanse slične.

Populaciju čini 10 individua, koje sve počinju svoj život kao minimalni hromozomi sa jednim slojem, 64 neurona i 32 embeddinga. Svaka jedinka se trenira 12 epoha, a zatim evaluira. Za selekciju se koristi tipična turnirska selekcija koja bira bira 3 nasumične jedinke, a pobednik među njima postaje roditelj. Tokom ukrštanja, dete nasleđuje arhitekturu boljeg roditelja, sa šansom od 30% da preuzme `learning_rate`, `batch_size` ili `embedding_dim` od slabijeg roditelja. Takođe, za svaki sloj postoji 30% šanse za zamenu veličine, aktivacione funkcije ili izostavljanja (engl. *dropout*). Stopa elitizma (engl. *elitism*) je 20%, te se uvek dve najbolje jedinke iz populacije direktno prenose u sledeću generaciju bez izmena.

Genetski algoritam je otkrio da je jednostavna arhitektura sa samo jednim skrivenim slojem dovoljna za ovaj problem. Neko bi možda počeo sa kompleksnijom mrežom (2-3 sloja), što bi rezultovalo sa mnogo više parametara, samim tim i sporijim treniranjem i potrebom za boljim računarskim resursima. Pristrasnost ka jednostavnosti je u ovom slučaju omogućila genetskom algoritmu da pronađe efikasno rešenje.

## 4. Autoenkoderi

Autoenkoder (engl. *autoencoder*) je vrsta neuronske mreže koja uči da komprimuje podatke u manji reprezentacioni prostor (engl. *encoding*), a zatim ih rekonstruiše nazad u originalni oblik (engl. *decoding*).

Struktura autoenkodera podrazumeva: *enkoder*, koji komprimuje ulaz u manji vektor (embedding); *latentni prostor*, najmanji sloj koji sadrži komprimovanu reprezentaciju; *dekoder*, koji rekonstruiše originalni ulaz iz embeddinga.

U kontekstu ovog projekta, autoenkoder prima 57-dimenzionalni vektor koji opisuje film i komprimuje ga u 32-dimenzionalni embedding. Tokom treniranja, mreža pokušava da minimizuje razliku između originalnog vektora i rekonstruisanog vektora. Proces učenja se odvija na sledeći način:

1. Ulaz predstavlja vektor sa 57 obeležja (žanrovi, godine, ocene, SVD faktori);
2. Enkoder ga komprimuje u 32 dimenzije;
3. Dekoder pokušava rekonstrukciju originalnih 57 dimenzija;
4. Funkcija gubitka (MSE) meri grešku rekonstrukcije;
5. Propagacija unazad ažurira težine ne bi li smanjila grešku.

Rezultat je 32-dimenzionalni embedding koji sadrži najvažnije informacije o filmu u komprimovanoj formi. Osim što se redukuje dimenzionalnost, embedding je na ovaj način naučio opšte obrasce i kombinacije obeležja, umesto da vrši puko memorisanje.

Nakon treniranja autoenkodera, enkoder se ekstrahuje kao samostalni model i koristi za generisanje 32-dimenzionalnih embeddinga za svih 9.711 filmova. Svi embedinzi se normalizuju na jediničnu dužinu za efikasno poređenje.

Funkcija preporuke funkcioniše po sledećem algoritmu:

1. Korisnik unosi naslove filmova koji mu se sviđaju;
2. Sistem pronalazi embedinge tih filmova;
3. Računa se prosečni vektor (query vektor);
4. Izračunava kosinusna sličnost sa svim filmovima;
5. Filmovi se rangiraju po sličnosti;
6. Vraća se top N preporuka.

## 5. Literatura

A NeuroEvolutionary Neural Network-Based Collaborative Filtering Recommendation System;  
Seyedamin Monemian<sup>2</sup>

Skripta iz Mašinskog učenja; Mladen Nikolić, Anđelka Zečević<sup>3</sup>

---

<sup>2</sup>

<https://laurentian.scholaris.ca/server/api/core/bitstreams/67369f2d-b5d0-4b4e-8995-2aecf18c8822/content>

<sup>3</sup> <https://ml.matf.bg.ac.rs/readings/ml.pdf>